

SISTEMAS INTELIGENTES DISTRIBUIDOS

Q2 2025–2026

Práctica 3

Estudio comparativo de algoritmos MARL
sobre el entorno POGEMA

Autores

Martí Checa
Óscar Nagl
Andreu Puerto

12 de junio de 2026

Índice

1. Introducción	3
2. El entorno POGEMA	3
2.1. Descripción	3
2.2. Señal de recompensa	4
2.3. Codificación del estado: <code>obs_to_state</code>	4
3. Implementación de los algoritmos	4
3.1. JAL-GT	4
3.2. IQL	5
3.3. Decisiones de implementación sobre el <i>baseline</i>	5
4. Hipótesis y diseño experimental	6
4.1. Hipótesis de partida	6
4.2. Parámetros fijos y su justificación	6
4.3. Densidades de obstáculos: 0.1 y 0.25	7
4.4. Grid de hiperparámetros: ϵ y γ	7
4.5. Métricas de evaluación	7
5. Experimento 1: Estudio conjunto de (ϵ, γ)	8
5.1. Configuración	8
5.2. Resultados	8
5.3. Análisis	8
6. Experimento 2: Transferencia de γ a IQL	9
6.1. Configuración	9
6.2. Objetivo	9
6.3. Análisis	9
7. Experimento 3: Validación del par óptimo en 10×10	10
7.1. Configuración	10
7.2. Objetivo	10
7.3. Análisis	10
8. Experimentos 4 y 5: IQL vs. JAL-GT	10
8.1. Configuración	10
8.2. Resultados: densidad 0.1 (EXP4)	11
8.3. Resultados: densidad 0.25 (EXP5)	11
8.4. Análisis	12
9. Experimento 6: Conceptos de solución en JAL-GT	13
9.1. Configuración	13
9.2. Resultados	14
9.3. Análisis	14
10. Experimento 7: Contraste situacional Pareto vs. Minimax	15
10.1. Configuración	15
10.2. Objetivo	15
10.3. Análisis	16

11. Ampliaciones	16
11.1. EXP8: <i>Decay</i> exponencial vs. lineal de ϵ (+1 punto)	16
11.1.1. Motivación	16
11.1.2. Resultados	16
11.1.3. Análisis	17
11.2. EXP9: Generalización a mapas no vistos (+0.5 puntos)	18
11.2.1. Motivación	18
11.2.2. Resultados	18
11.2.3. Análisis	18
11.3. EXP10: Parejas heterogéneas de conceptos de solución (+0.5 puntos)	19
11.3.1. Motivación	19
11.3.2. Resultados	19
11.3.3. Análisis	19
12. Análisis global y conclusiones	19
12.1. Verificación de las hipótesis	19
12.2. Tabla resumen	20
12.3. Conclusiones y recomendaciones	20

1 Introducción

Esta práctica extiende el trabajo de la Práctica 2 (Q-Learning tabular sobre FrozenLake) al dominio del aprendizaje por refuerzo multiagente (*Multi-Agent Reinforcement Learning*, MARL). El salto conceptual es importante: en entornos con varios agentes, cada uno experimenta un entorno *no-estacionario*, porque el comportamiento de los demás agentes cambia mientras todos aprenden a la vez.

El estudio compara dos algoritmos de la familia MARL tabular sobre el entorno POGEMA (*Partially-Observable Grid Environment for Multiple Agents*):

- **IQL** (*Independent Q-Learning*): traslado directo del Q-Learning de la Práctica 2 al escenario multiagente, donde cada agente aprende su Q-table individual *ignorando* la existencia del resto.
- **JAL-GT** (*Joint-Action Learning with Game Theory*): extiende Q-Learning a acciones conjuntas y determina la política mediante un *concepto de solución* de la teoría de juegos (Nash, Pareto, *Welfare* o Minimax).

El foco del análisis está en tres preguntas: (1) ¿Cómo afecta la no-estacionariedad a IQL frente a JAL-GT? (2) ¿Qué concepto de solución induce mejor coordinación en un entorno cooperativo? (3) ¿Cómo escalan ambas diferencias con el tamaño del mapa y la densidad de obstáculos?

2 El entorno POGEMA

2.1 Descripción

POGEMA es un entorno bidimensional multiagente con observabilidad parcial. El mapa es una cuadrícula de tamaño $N \times N$ con obstáculos (incluyendo siempre el perímetro exterior). Los agentes comienzan en posiciones aleatorias determinadas por una semilla y tienen cada uno un objetivo propio. La recompensa por defecto es +1 cuando un agente alcanza su objetivo, tras lo cual desaparece del mapa.

Las características relevantes para nuestra experimentación son:

- **Observabilidad parcial:** cada agente recibe una observación local correspondiente a la cuadrícula $(x \pm r, y \pm r)$ centrada en él, donde r es el radio de observación. Con $r = 1$ la observación es una cuadrícula 3×3 formada por tres matrices:
 - Matriz de obstáculos (1 si hay obstáculo, 0 si no).
 - Matriz de otros agentes (1 si hay otro agente, 0 si no).
 - Matriz de objetivo (1 único en la casilla más cercana al objetivo propio).
- **Ejecución paralela:** todos los agentes actúan a la vez. Si dos agentes intentan ocupar la misma posición, el de identificador menor accede y el otro no se mueve (*choque*).
- **Espacio de acciones:** 5 acciones discretas: STAY, UP, DOWN, LEFT, RIGHT.
- **Episodio truncado:** se corta tras `episode_length` pasos si no todos los agentes han llegado a su objetivo.

2.2 Señal de recompensa

Para incentivar la eficiencia de las trayectorias, añadimos una penalización por paso de $-0,01$ mediante un `RewardWrapper` aplicado sobre el entorno base:

$$r_t = \begin{cases} +1 & \text{si el agente alcanza su objetivo en el paso } t, \\ -0,01 & \text{en cualquier otro caso.} \end{cases} \quad (1)$$

Esta penalización está alineada con la Práctica 2, donde *step penalty* pequeño con recompensa terminal positiva favorece aprender caminos cortos sin colapsar la señal de aprendizaje. En el peor caso (16 pasos, ningún agente llega, 10 mapas, 2 agentes), la recompensa colectiva mínima es $10 \times 2 \times (-0,16) = -3,2$.

2.3 Codificación del estado: obs_to_state

Para poder aplicar algoritmos tabulares sobre las observaciones matriciales, es necesario convertirlas a un entero discreto. La función `obs_to_state` del *baseline* codifica la observación 3×3 en un entero $s \in [0, 1023]$ de la siguiente forma:

- **Objetivo** (2 bits): clasifica la dirección relativa al objetivo en cuatro zonas (arriba, abajo, izquierda, derecha).
- **Obstáculos** (4 bits): uno por cada dirección cardinal.
- **Otros agentes** (4 bits): ídem para las cuatro direcciones cardinales.

El espacio resultante tiene $2^{10} = 1024$ estados posibles, independientemente del tamaño del mapa (la observación es siempre local, de radio 1). Esta compacidad es la que hace viable la comparativa tabular en mapas de 4×4 , 6×6 y 10×10 .

3 Implementación de los algoritmos

3.1 JAL-GT

JAL-GT es una extensión de Q-Learning al dominio multiagente donde las Q-tables son conjuntas: $\mathbf{Q} \in \mathbb{R}^{N \times S \times |AS|}$, donde N es el número de agentes, S el espacio de estados y AS el espacio de *acciones conjuntas*. Con 2 agentes y 5 acciones, $|AS| = 25$ y el tamaño total de la Q-table es $2 \times 1024 \times 25 = 51\,200$ entradas.

La actualización de Q-values sigue la ecuación de diferencias temporales:

$$Q_i(s, \mathbf{a}) \leftarrow Q_i(s, \mathbf{a}) + \alpha [r_i + \gamma \cdot V_i(s') - Q_i(s, \mathbf{a})], \quad (2)$$

donde el valor de un estado para el agente i se calcula a partir de la política conjunta π^* derivada por el concepto de solución:

$$V_i(s) = \sum_{\mathbf{a} \in AS} Q_i(s, \mathbf{a}) \prod_{j=1}^N \pi_j^*(a_j | s). \quad (3)$$

La política conjunta se actualiza en cada paso con el concepto de solución activo, usando la Q-table como si fuera la matriz de recompensas de un juego estático. Esta actualización en cada step es relevante porque crea un *bucle de retroalimentación*: la Q-table cambia $\rightarrow$ la política conjunta cambia $\rightarrow$ los targets cambian $\rightarrow$ la Q-table cambia de nuevo.

Los cuatro conceptos de solución implementados son:

- **Nash**: acción conjunta tal que ningún agente puede mejorar desviándose unilateralmente. Se implementa mediante cruce de mejores respuestas; si hay más de un equilibrio, la probabilidad se reparte uniformemente.
- **Pareto**: acción conjunta no dominada; no existe otra que mejore a todos los agentes simultáneamente. Si hay múltiples óptimos de Pareto, la probabilidad se reparte uniformemente.
- **Welfare**: acción conjunta que maximiza la suma de recompensas de todos los agentes.
- **Minimax**: cada agente elige la acción que minimiza el máximo beneficio del oponente. Diseñado para entornos competitivos de suma cero.

3.2 IQL

IQL es el mismo Q-Learning tabular de la Práctica 2, aplicado de forma independiente por cada agente. Cada agente mantiene su propia Q-table $Q \in \mathbb{R}^{S \times |A|}$ (con $|A| = 5$, tamaño total $1024 \times 5 = 5120$ entradas) y aprende mediante:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]. \quad (4)$$

La diferencia fundamental respecto a JAL-GT es que IQL no modela las acciones del otro agente: desde el punto de vista de cada agente, el entorno es uniagente. Esto viola la asunción de estacionariedad que Q-Learning necesita para converger, porque la política del otro agente cambia durante el entrenamiento.

Cabe destacar la diferencia en tamaño de Q-table: JAL-GT tiene $10 \times$ más entradas que IQL (51 200 frente a 5 120 por agente). Con el mismo presupuesto de muestras, cada entrada de JAL-GT recibe de media $10 \times$ menos actualizaciones que cada entrada de IQL, lo que tiene un impacto directo sobre la calidad del aprendizaje.

3.3 Decisiones de implementación sobre el *baseline*

El código *baseline* de los profesores incluye JAL-GT, el entorno, la función `obs_to_state` y los conceptos de solución. Los cambios que hemos introducido son los siguientes:

IQL (nueva clase en `algorithms.py`). IQL no estaba en el *baseline*; lo implementamos como subclase de `MARLAlgorithm` siguiendo la misma interfaz (`learn`, `select_action`, `explain`), de forma que el bucle de entrenamiento en `main.py` funciona con IQL sin ningún cambio adicional. Acepta `**kwargs` para ser compatible con `build_algorithms`.

Semillas variables entre runs (`main.py`). El *baseline* fijaba la semilla de exploración de cada agente a `agent_id`, por lo que los 10 runs de la batería producían entrenamientos idénticos y la varianza inter-seed era cero por construcción. Lo corregimos añadiendo un parámetro `base_seed` en `build_algorithms`:

```
seed = base_seed * 100 + agent_id
```

Si `base_seed=0` (valor por defecto), el comportamiento es idéntico al original; retrocompatibilidad total. Tras el fix, la varianza inter-seed típica es de 0.53.

Vista global para los SVG de evaluación. El *baseline* guardaba SVGs en vista egocéntrica (uno por agente), cuyas coordenadas no son comparables entre agentes y por tanto no permiten detectar colisiones reales. Cambiamos a `egocentric_idx=None` (vista global), que sitúa ambos agentes en el mismo sistema de referencia y habilita el análisis automático de deadlocks y colisiones.

4 Hipótesis y diseño experimental

4.1 Hipótesis de partida

Antes de ejecutar ningún experimento formulamos las siguientes hipótesis, derivadas de las propiedades teóricas de los algoritmos y del conocimiento adquirido en la Práctica 2:

1. **JAL-GT $\geq$ IQL en recompensa colectiva.** JAL-GT modela explícitamente la coordinación mediante acciones conjuntas; IQL ignora al otro agente y por tanto es ciego a los incentivos de coordinación.
2. **IQL muestra mayor inestabilidad intra-run que JAL-GT.** La no-estacionariedad se manifiesta como oscilaciones en la curva de recompensa durante el entrenamiento: el target de Q-Learning cambia porque la política del otro agente evoluciona. JAL-GT internaliza este cambio en su función de valor conjunta.
3. **La brecha IQL vs. JAL-GT crece con el tamaño del mapa y la densidad.** En mapas grandes y densos, los episodios son más largos, la coordinación es más crítica y la no-estacionariedad de IQL se acumula durante más pasos.
4. **γ alto es necesario para propagar la recompensa terminal.** El objetivo puede estar a varios pasos de distancia, y la penalización de $-0,01$ por paso hace que con γ bajo la señal de la recompensa terminal ($+1$) quede atenuada.
5. **ϵ alto reduce la varianza inter-seed.** Un ϵ inicial alto garantiza que todos los runs cubren suficiente espacio de estados durante la exploración, reduciendo la dependencia de la seed.
6. **Ranking de conceptos de solución: Pareto/Welfare $>$ Nash $>$ Minimax.** En un entorno cooperativo, Pareto y Welfare optimizan directamente para la utilidad conjunta. Nash puede llegar a equilibrios en los que “ambos agentes se quedan quietos”. Minimax trata al colaborador como adversario.
7. **La brecha entre conceptos se amplifica con el tamaño del mapa.** En mapas grandes, la coordinación importa más y los conceptos inadecuados se penalizan más.

4.2 Parámetros fijos y su justificación

Los parámetros de la Tabla 1 son comunes a todos los experimentos y se justifican a continuación.

Cuadro 1: Parámetros fijos en todos los experimentos.

Parámetro	Valor	Justificación
Número de agentes	2	Restricción del enunciado
num_states	1024	Consecuencia de obs_to_state (2^{10})
maps	10	Equilibrio diversidad/frecuencia de visita
episodes_per_epoch	10	Resolución suficiente sin exceso de ruido
episode_length	16	Valor <i>baseline</i> de los profesores
α (learning rate)	0.01	Fijado por los profesores; no se estudia
$\epsilon_{\min}$	0.1	Cota inferior <i>baseline</i>
Seeds de entrenamiento	0–9 (10 seeds)	Varianza inter-seed robusta
Epochs	200	Suficiente para ver convergencia en todos los tamaños

Tasa de aprendizaje $\alpha = 0,01$. El *baseline* de esta práctica fija $\alpha = 0,01$, un orden de magnitud inferior al valor óptimo en la Práctica 2 ($\alpha = 0,1$). La razón es que JAL-GT actualiza la Q-table con un *target* inestable (la función de valor conjunta $V_i(s')$ depende de la política conjunta que cambia en cada paso). Un α bajo amortigua estas oscilaciones. No estudiamos α porque el enunciado lo excluye explícitamente del alcance.

Número de semillas (10). La Práctica 2 mostró que con 5 seeds los algoritmos con ϵ bajo exhibían varianza inter-seed de hasta 30 puntos porcentuales. Con 10 seeds obtenemos estimaciones más robustas de la media y la varianza sin un coste computacional prohibitivo.

4.3 Densidades de obstáculos: 0.1 y 0.25

La densidad de obstáculos controla la complejidad del entorno. En vez de elegir a ojo, verificamos empíricamente la resolubilidad y el ratio de rodeo de cada densidad candidata mediante búsqueda en anchura (BFS) sobre 500 mapas generados aleatoriamente.

- **Densidad baja = 0.1:** $\approx 98\%$ de mapas resolubles; ratio de rodeo $\approx 1,03$. Con pocos obstáculos, el conflicto entre agentes proviene de sus interacciones directas, no del entorno. Aísla la coordinación pura.
- **Densidad media = 0.25:** $\geq 84\%$ de mapas resolubles; ratio de rodeo $\approx 1,13$ en 6×6 y $\approx 1,21$ en 10×10 . Los obstáculos fuerzan desviaciones visibles del camino óptimo, añadiendo presión sobre la coordinación.

Descartamos 0.3 porque aumentaba la fracción de mapas irresolubles al 7–9%, lo que introduciría ruido en la comparativa. Los mapas irresolubles se filtran en el análisis SVG.

4.4 Grid de hiperparámetros: ϵ y γ

Estudiamos el efecto de $\epsilon_{\max}$ y γ mediante un **grid conjunto** 3×3 , no secuencialmente, porque los dos parámetros están acoplados: el ϵ óptimo puede depender del γ .

- $\gamma \in \{0,90, 0,95, 0,99\}$: rango validado en la Práctica 2 sobre Q-Learning tabular.
- $\epsilon_{\max} \in \{0,5, 0,75, 1,0\}$: saltos uniformes de 0.25 en la zona exploratoria razonable.

El par óptimo (ϵ^*, γ^*) encontrado en el experimento 1 se traslada automáticamente a los experimentos 2–7.

4.5 Métricas de evaluación

Para cada run registramos las siguientes métricas:

- **Recompensa colectiva e individual** por epoch (la individual detecta asimetrías entre agentes).
- **TD error** por epoch (firma de convergencia: decrece en Q-Learning estable, oscila bajo no-estacionariedad).
- **Tiempo de entrenamiento** por run (JAL-GT actualiza 25 acciones conjuntas por paso frente a 5 de IQL).
- **Varianza inter-seed:** dispersión de la recompensa final entre las 10 seeds.


- **Inestabilidad intra-run:** desviación típica de la recompensa en ventana móvil de 20 epochs, calculada sobre la segunda mitad del entrenamiento. Esta es la métrica directa de no-estacionariedad.
- **Epoch de convergencia:** primer epoch donde la media móvil (ventana 20) supera el percentil 90 de la recompensa del run. Usamos el percentil 90 en vez del máximo para evitar que un pico espurio se tome como convergencia.

5 Experimento 1: Estudio conjunto de (ϵ, γ)

5.1 Configuración

Algoritmo: JAL-GT con concepto Pareto. **Mapa:** 4×4 . **Densidad:** 0.1. **Seeds:** 0–9 (10 seeds por celda del grid). **Grid:** $\epsilon_{\max} \in \{0,5, 0,75, 1,0\} \times \gamma \in \{0,90, 0,95, 0,99\}$ (9 runs).

5.2 Resultados



(a) Recompensa en convergencia.

(b) Varianza inter-seed (menor es mejor).

Figura 1: EXP1: heatmaps de la búsqueda de hiperparámetros (JAL-GT Pareto, 4×4 , densidad 0.1). El ganador por recompensa es $(\epsilon = 0,5, \gamma = 0,9)$, aunque con la varianza inter-seed más alta del grid.

El par óptimo por recompensa de convergencia es $(\epsilon^*, \gamma^*) = (0,5, 0,9)$, con una recompensa en convergencia de 12,47 y una varianza inter-seed de 2,01. El segundo mejor por recompensa es $(\epsilon = 1,0, \gamma = 0,99)$ con 12,42 y varianza 1,24.

5.3 Análisis

Hipótesis 4 y 5 refutadas. Los datos contradicen ambas hipótesis de partida: el ganador tiene $\gamma = 0,90$ (no alto) y $\epsilon = 0,5$ (el más bajo del grid). Esto tiene una explicación mecánica clara.

Por qué gana $\gamma = 0,9$ en 4×4 . Con densidad 0.1 y `episode_length=16`, los objetivos son alcanzables en 3–5 pasos en la mayoría de episodios. Con $\gamma = 0,9$ y 3 pasos de distancia, la señal de la recompensa terminal queda atenuada a $0,9^3 = 0,73$; suficiente para aprender. Las ventajas de γ más alto (mayor propagación) no compensan el coste de converger más lentamente, porque el espacio de estados es pequeño y las trayectorias son cortas.

Por qué gana $\epsilon = 0,5$ en 4×4 . En un mapa 4×4 con 1024 estados posibles (representación local), el espacio efectivo de estados visitados es pequeño y se cubre rápidamente con exploración moderada. Un $\epsilon_{\text{máx}} = 1,0$ mantiene al agente explorando de forma casi aleatoria durante más epochs, reduciendo el tiempo efectivo de explotación antes del final del entrenamiento. $\epsilon = 0,5$ produce un equilibrio exploración/explotación más favorable en este régimen.

Trade-off recompensa vs. robustez. El par ganador ($\epsilon = 0,5, \gamma = 0,9$) tiene la varianza inter-seed más alta del grid (2.01), exactamente lo contrario de lo que predecía la hipótesis 5. El par más robusto es ($\epsilon = 0,75, \gamma = 0,9$) con recompensa 12,06 y varianza solo 1,12. Elegimos maximizar la recompensa de convergencia porque los experimentos siguientes promedian 10 seeds, por lo que la varianza inter-seed se amortigua. Esta decisión se documenta explícitamente como *trade-off*.

Interacción ϵ - γ . La matriz no es monótona en ninguna dirección, lo que justifica retrospectivamente el diseño del grid conjunto. La interacción es no lineal.

El par $(\epsilon^*, \gamma^*) = (0,5, 0,9)$ se traslada a todos los experimentos siguientes.

6 Experimento 2: Transferencia de γ a IQL

6.1 Configuración

Algoritmo: IQL. **ϵ fijo:** $\epsilon^* = 0,5$. **Mapa:** 4×4 . **Densidad:** 0.1. **Barrido:** $\gamma \in \{0,90, 0,95, 0,99\}$.

6.2 Objetivo

Verificar si el γ óptimo de JAL-GT es también razonable para IQL. Si el γ óptimo difiere, usaremos el de JAL-GT en la comparativa por *fairness* y documentaremos el hallazgo.




Figura 2: EXP2: recompensa en convergencia de IQL en función de γ (mapa 4×4 , densidad 0.1, $\epsilon = 0,5$). Recompensas: $\gamma = 0,9$: 13.19; $\gamma = 0,95$: 12.86; $\gamma = 0,99$: 12.12.

6.3 Análisis

El γ óptimo de IQL es $\gamma = 0,9$, con una recompensa en convergencia de 13,19. Coincide exactamente con el de JAL-GT ($\gamma^* = 0,9$), lo que indica que la preferencia por $\gamma = 0,9$ en el régimen 4×4 es robusta al algoritmo y viene determinada principalmente por la estructura

del entorno (trayectorias cortas), no por las diferencias algorítmicas. Esto garantiza **fairness perfecta** en la comparativa de los experimentos 4 y 5.

Un hallazgo adicional es que IQL ya obtiene aquí 13,19 frente a 12,47 de JAL-GT en el mismo escenario. Esta es la primera señal de que la hipótesis 1 ($\text{JAL-GT} \geq \text{IQL}$) podría no confirmarse, y anticipa el análisis de los experimentos 4 y 5.

7 Experimento 3: Validación del par óptimo en 10×10

7.1 Configuración

Algoritmo: JAL-GT Pareto. **Mapa:** 10×10 . **Densidad:** 0.1. **Comparativa:** par óptimo $(\epsilon^*, \gamma^*) = (0,5, 0,9)$ vs. *baseline* $(1,0, 0,95)$.

7.2 Objetivo

Verificar si el par óptimo calibrado en 4×4 transfiere a mapas grandes. Es una prueba honesta de la validez externa de la calibración.




Figura 3: EXP3: curvas de recompensa colectiva del par óptimo vs. *baseline* en 10×10 (densidad 0.1, bandas = desviación típica inter-seed). Recompensa en convergencia: 9.90 (óptimo) vs. 9.54 (*baseline*).

7.3 Análisis

El par $(\epsilon^*, \gamma^*) = (0,5, 0,9)$ obtiene una recompensa en convergencia de 9,90, superior al *baseline* (9,54), una mejora del +3,7%. La transferencia del par óptimo se confirma: aunque los mapas 10×10 tienen trayectorias más largas que los 4×4 , el valor $\gamma = 0,9$ sigue siendo suficiente para propagar la señal de recompensa. Esto justifica usar este par en todos los experimentos siguientes.

8 Experimentos 4 y 5: IQL vs. JAL-GT

8.1 Configuración

Algoritmos: IQL y JAL-GT-Pareto. **Tamaños:** 4×4 , 6×6 , 10×10 . **Densidades:** 0.1 (EXP4) y 0.25 (EXP5). **Hiperparámetros:** $(\epsilon^*, \gamma^*) = (0,5, 0,9)$.

Estos dos experimentos constituyen la **comparativa algorítmica principal** de la práctica. Por cada combinación de algoritmo, tamaño y densidad corremos 10 seeds y reportamos media $\pm$ desviación típica.

8.2 Resultados: densidad 0.1 (EXP4)




Figura 4: EXP4: recompensa colectiva por epoch, IQL vs. JAL-GT-Pareto (densidad 0.1). Las bandas representan la desviación típica inter-seed.

Cuadro 2: EXP4 (densidad 0.1): métricas clave por tamaño.

Tamaño	Alg.	Conv.	Conv. epoch	Inestab. intra-run	Tiempo (s)
4×4	IQL	13.19	62	0.039	6.1
4×4	JAL-GT	12.47	131	0.482	41.5
6×6	IQL	11.99	116	0.038	7.7
6×6	JAL-GT	9.01	129	0.471	49.7
10×10	IQL	9.14	—	0.064	10.3
10×10	JAL-GT	9.90	—	0.535	54.9

8.3 Resultados: densidad 0.25 (EXP5)




Figura 5: EXP5: recompensa colectiva por epoch, IQL vs. JAL-GT-Pareto (densidad 0.25). Las bandas representan la desviación típica inter-seed.

Cuadro 3: EXP5 (densidad 0.25): métricas clave por tamaño.

Tamaño	Alg.	Conv.	Conv. epoch	Inestab. intra-run	Tiempo (s)
4×4	IQL	14.31	62	0.027	5.5
4×4	JAL-GT	13.86	131	0.426	38.3
6×6	IQL	6.58	—	0.177	8.2
6×6	JAL-GT	4.49	—	0.579	56.0
10×10	IQL	4.35	—	0.624	10.1
10×10	JAL-GT	1.97	—	0.597	53.8

8.4 Análisis

Hipótesis 1 refutada: IQL supera a JAL-GT en 5 de 6 configuraciones. El resultado más llamativo del estudio es que IQL supera a JAL-GT en recompensa de convergencia en 5 de las 6 combinaciones tamaño×densidad (excepción: 10×10 , densidad 0.1, donde JAL-GT obtiene 9,90 frente a 9,14 de IQL). Este resultado contradice la hipótesis 1 y merece una explicación mecanística:

- **Desequilibrio en la densidad de datos.** JAL-GT mantiene una Q-table de $2 \times 1024 \times 25 = 51\,200$ entradas; IQL mantiene $1024 \times 5 = 5\,120$ entradas por agente. Con $\alpha = 0,01$ y $200 \text{ epochs} \times 10 \text{ episodios} \times 16 \text{ pasos} = 32\,000$ transiciones de entrenamiento, cada entrada de JAL-GT recibe de media $\approx 0,6$ actualizaciones, frente a $\approx 6,2$ de IQL. JAL-GT sufre un **underfitting severo**: su Q-table nunca llega a estar bien poblada en el régimen de entrenamiento de la práctica, y las políticas derivadas del concepto de solución sobre Q-values ruidosos son subóptimas.
- **¿Por qué JAL-GT sí gana en 10×10 , densidad 0.1?** En mapas grandes con baja densidad, los agentes se encuentran con más frecuencia en trayectorias largas, y hay más valor en modelar las acciones conjuntas. Además, en 10×10 el espacio de estados de IQL también tiene peor cobertura relativa, igualando parcialmente las condiciones de aprendizaje. Este es el único escenario donde la ventaja teórica de JAL-GT (modelar coordinación) supera su desventaja de datos.

La conclusión práctica no es que JAL-GT sea un algoritmo peor, sino que con un presupuesto de muestras limitado y α conservador, **IQL es una línea base muy difícil de superar**: aprende más eficientemente porque su espacio de parámetros es 10 veces más pequeño.

Hipótesis 2 invertida: JAL-GT es más inestable que IQL. La inestabilidad intra-run de JAL-GT es sistemáticamente mayor que la de IQL en todas las configuraciones (Tablas 2 y 3). Por ejemplo, en 6×6 con densidad 0.1: IQL tiene inestabilidad 0,038 frente a 0,471 de JAL-GT, una diferencia de $12\times$.

La causa de esta inversión no es que la no-estacionariedad no afecte a IQL, sino que JAL-GT genera su propia inestabilidad interna. En cada paso de entrenamiento, JAL-GT ejecuta el bucle: (1) actualizar Q-table con α , (2) recomputar la política conjunta con el concepto de solución (Pareto) sobre la nueva Q-table, (3) calcular $V_i(s')$ con la política actualizada. Esto crea un *bucle de retroalimentación*: la Q-table cambia $\rightarrow$ la política conjunta cambia $\rightarrow$ los targets de Q-Learning cambian $\rightarrow$ la Q-table cambia de nuevo. Esta inestabilidad es *endógena* al propio algoritmo, no consecuencia de que el otro agente cambie.

IQL, en cambio, tiene un target de Q-Learning más estable porque no recomputa ninguna política conjunta: simplemente toma el máximo sobre sus propios Q-values. Aunque el entorno que percibe IQL es técnicamente no-estacionario (la política del otro agente evoluciona), su

espacio de parámetros pequeño le permite converger a sus Q-values correctos antes de que esa no-estacionariedad acumule un efecto significativo.

La firma de no-estacionariedad sobre IQL solo se vuelve visible en el único caso donde el espacio es lo suficientemente grande: EXP5, 10×10 , densidad 0.25, donde IQL presenta inestabilidad 0,624 frente a 0,597 de JAL-GT. Este es el único caso donde la no-estacionariedad clásica de IQL supera la inestabilidad endógena de JAL-GT.

Hipótesis 3 refutada: la brecha no favorece a JAL-GT. La brecha JAL-GT – IQL es *negativa* en 5 de 6 casos y se vuelve más negativa al aumentar la densidad. Con densidad 0.25 y mapa 10×10 : IQL obtiene 4,35 frente a 1,97 de JAL-GT ($-2,38$). Los obstáculos adicionales no aportan el impulso de coordinación esperado para JAL-GT, porque su Q-table, aún más infraexplotada en estos escenarios complejos, produce políticas aún más ruidosas.

Asimetría individual en EXP5 10×10 . En el escenario más exigente (EXP5, 10×10), las recompensas individuales revelan un comportamiento preocupante de JAL-GT: agente 0 obtiene +2,69 pero agente 1 obtiene $-0,47$ (recompensa colectiva = 1,97, solo paso penalties, nunca llega al objetivo). JAL-GT, al optimizar conjuntamente, puede sacrificar a un agente para coordinar al otro, con resultado colectivo peor que si cada agente actuara independientemente. IQL evita esta asimetría por construcción: cada agente solo optimiza su propia recompensa.

Coste computacional. JAL-GT tarda de media ≈ 50 s por run frente a ≈ 8 s de IQL en 6×6 , un factor de $\approx 6\times$. El sobrecoste se debe a que JAL-GT actualiza 25 entradas de Q-table por paso y recomputa el concepto de solución en cada step. En los escenarios donde IQL es competitivo o superior (la mayoría), este coste computacional adicional no está justificado.

Análisis de los SVG (6×6 , densidad 0.25). Los SVGs generados durante la evaluación final revelan patrones complementarios. Ambos algoritmos muestran 0 % de deadlocks y 0 % de colisiones, pero difieren en eficiencia de trayectoria: IQL alcanza 0,66 de media frente a 0,58 de JAL-GT (donde 1,0 es camino directo). Ambos exhiben un 100 % de patrones de cesión de paso (un agente rodea para dejar pasar al otro), lo que indica que ambos aprenden a coordinarse. La mayor eficiencia de IQL sugiere que sus trayectorias son menos tortuosas, probablemente porque su política es más consistente.


9 Experimento 6: Conceptos de solución en JAL-GT

9.1 Configuración


Algoritmo: JAL-GT con cada uno de los cuatro conceptos (Nash, Pareto, Welfare, Minimax). **Mapa:** 6×6 . **Densidades:** 0.1 y 0.25. **Hiperparámetros:** (ϵ^*, γ^*) .

El tamaño 6×6 es el punto dulce para este experimento: suficientemente grande para que la coordinación importe y suficientemente pequeño para que todos los conceptos tengan tiempo de mostrar su efecto en 200 epochs.

9.2 Resultados




(a) Densidad 0.1.




(b) Densidad 0.25.

Figura 6: EXP6: curvas de recompensa colectiva por concepto de solución (6×6).



(a) Densidad 0.1.



(b) Densidad 0.25.

Figura 7: EXP6: ranking de conceptos por recompensa en convergencia (6×6).

Cuadro 4: EXP6: recompensa en convergencia por concepto y densidad (6×6).

Concepto	Densidad 0.1	Densidad 0.25
Nash	11.63	4.31
Pareto	9.01	4.49
Welfare	6.64	1.88
Minimax	-2,45	-2,41

9.3 Análisis

Rankings y cambio de densidad. Con densidad 0.1: Nash (11,63) > Pareto (9,01) > Welfare (6,64) > Minimax (-2,45). Con densidad 0.25: Pareto (4,49) $\approx$ Nash (4,31) > Welfare (1,88) > Minimax (-2,41). La hipótesis 6 (Pareto/Welfare > Nash > Minimax) solo se confirma parcialmente.

Nash supera a Pareto en densidad baja. Nash selecciona la acción conjunta como mejor respuesta cruzada: un cálculo relativamente directo sobre los Q-values actuales. Pareto, en cambio, debe enumerar todas las acciones conjuntas no dominadas entre las 25 posibles. Con Q-tables escasamente pobladas, el cálculo de Pareto introduce más ruido en la política. Con densidad baja

(0.1), los agentes raramente se interfieren y la mejor respuesta individual (Nash) produce trayectorias casi directas. Al subir la densidad (0.25), evitar deadlocks se vuelve crítico, y aquí Pareto asciende al primer puesto.

Welfare por debajo de lo esperado. Welfare maximiza la suma de Q-values. En fases iniciales con Q-values muy ruidosos, maximizar la suma puede llevar a acciones conjuntas subóptimas en el entorno real. Además, puede converger a soluciones donde un agente “subsida” a otro, produciendo asimetrías individuales.

Minimax: resultado catastrófico confirmado por SVG. Minimax obtiene recompensas negativas en ambas densidades. En POGEMA, donde el otro agente es un colaborador, la lógica de minimizar el beneficio del oponente es directamente contraproducente: ambos agentes actúan para reducir la recompensa del otro, produciendo inacción mutua.

El análisis automático de SVG (densidad 0.25) confirma esto de forma espectacular:

- **Minimax:** 100 % de episodios con deadlock, 66,7 % con ambos agentes completamente inmóviles; eficiencia media 0,17.
- **Pareto:** 0 % de deadlocks, 100 % de patrones de cesión de paso; eficiencia media 0,58.
- **Nash:** 33,3 % de deadlocks (un agente inmóvil), 66,7 % de cesiones; eficiencia media 0,39.
- **Welfare:** 33,3 % de deadlocks, 33,3 % de cesiones; eficiencia media 0,19.

El contraste entre Minimax (todos bloqueados) y Pareto (ningún bloqueo, todos ceden) demuestra que el concepto de solución determina cualitativamente el comportamiento emergente de los agentes.

10 Experimento 7: Contraste situacional Pareto vs. Minimax

10.1 Configuración

Algoritmo: JAL-GT con Pareto y Minimax. **Mapas:** 4×4 y 10×10 . **Densidad:** 0.1. **Hiperparámetros:** (ϵ^*, γ^*) .

10.2 Objetivo

Comprobar si el ranking entre conceptos depende del tamaño del mapa. La hipótesis 7 predice que la diferencia entre conceptos se amplifica con el tamaño.




Figura 8: EXP7: Pareto vs. Minimax en tamaños extremos (densidad 0.1). Recompensas Pareto: 12.47 (4×4) y 9.90 (10×10). Recompensas Minimax: -1,51 (4×4) y -2,42 (10×10).

10.3 Análisis

La brecha Pareto – Minimax es +13,99 en 4×4 y +12,32 en 10×10 . La hipótesis 7 queda **refutada técnicamente**: la diferencia no se amplifica con el tamaño.

Sin embargo, la interpretación correcta es que la hipótesis no llega a fallar por las razones esperadas, sino por un *efecto suelo*: Minimax ya produce deadlocks totales en 4×4 (recompensa $-1,51 \approx -0,01 \times 16 \times$ episodios para agentes inmóviles). No hay margen para que la penalización se amplifique en 10×10 porque el algoritmo ya ha alcanzado el mínimo posible en el mapa pequeño.

La conclusión robusta es que Minimax es inadecuado para entornos cooperativos independientemente del tamaño, y que esta inadecuación ya se manifiesta completamente en 4×4 .

11 Ampliaciones

11.1 EXP8: *Decay* exponencial vs. lineal de ϵ (+1 punto)

11.1.1. Motivación

El *baseline* usa un *decay* lineal de ϵ :

$$\epsilon_t = \epsilon_{\max} - \frac{t}{T-1}(\epsilon_{\max} - \epsilon_{\min}), \quad (5)$$

donde t es el episodio global y T el total de episodios.

Alternativa: *decay* exponencial que concentra la exploración al inicio:

$$\epsilon_t = \epsilon_{\min} + (\epsilon_{\max} - \epsilon_{\min}) e^{-kt}, \quad (6)$$

donde k se calibra para que $\epsilon_T \approx \epsilon_{\min}$ ($e^{-k(T-1)} = 0,01$).

Hipótesis (H6): el exponencial debería converger antes en mapas medianos (6×6), donde la fase de explotación es más larga. En mapas pequeños (4×4) la diferencia debería ser marginal. La comparativa es *apples-to-apples*: mismo $\epsilon_{\max}$, mismo $\epsilon_{\min}$, mismo número de episodios.

11.1.2. Resultados





Figura 9: EXP8: perfil de $\epsilon(t)$ para *decay* lineal y exponencial.

Figura 10: EXP8: *decay* lineal vs. exponencial en IQL y JAL-GT.Cuadro 5: EXP8: comparativa *decay* lineal vs. exponencial.

Alg.	Tamaño	Epoch convergencia		Recompensa convergencia		Recomendación
		Lineal	Exp.	Lineal	Exp.	
IQL	4×4	62	106	13.19	13.62	Lineal más rápido; diff. < 3 %
IQL	6×6	116	61	11.99	11.04	Exp. más rápido (H6 ✓)
JAL-GT	4×4	131	148	12.47	11.84	Lineal mejor en ambas métricas
JAL-GT	6×6	129	125	9.01	8.45	Lineal mejor en recompensa

11.1.3. Análisis

H6 confirmada parcialmente: en IQL 6×6 , el exponencial converge en el epoch 61 frente al epoch 116 del lineal, casi el doble de rápido.

H6 refutada en recompensa final: el exponencial converge antes pero a una política de menor calidad (11,04 vs. 11,99). La exploración más corta en la segunda mitad reduce la diversidad de experiencias y produce Q-values menos refinados.

Para JAL-GT: el lineal es mejor en ambas métricas. JAL-GT ya tiene su propia fuente de exploración implícita (la política conjunta varía mucho por sus Q-values ruidosos), por lo que el exponencial no aporta beneficio adicional.

Recomendación: usar *decay* exponencial en IQL únicamente cuando la velocidad de convergencia sea prioritaria sobre la calidad final. Para JAL-GT, el *decay* lineal es preferible en todos los casos analizados.

11.2 EXP9: Generalización a mapas no vistos (+0.5 puntos)

11.2.1. Motivación

Entrenamos en semillas 0–9 y evaluamos en semillas 100–109 (nunca vistas durante el entrenamiento).

Hipótesis (H7): la función `obs_to_state` es independiente de la posición absoluta del agente (radio 1, solo información local). Esto implica que la mayoría de los estados observados en mapas nuevos ya habrán sido vistos durante el entrenamiento. La **cobertura de estados** (fracción de estados visitados en test que también aparecieron en train) es la métrica explicativa.

11.2.2. Resultados




Figura 11: EXP9: recompensa en mapas de entrenamiento vs. mapas no vistos.

Cuadro 6: EXP9: gap de generalización y cobertura de estados.

Alg.	Tamaño	Dens.	Train	Test	Gap	Cobertura
IQL	4 × 4	0.1	0.95	0.72	0.23	54,5 %
IQL	4 × 4	0.25	1.64	0.04	1.59	52,0 %
IQL	6 × 6	0.1	1.16	0.49	0.67	45,7 %
IQL	10 × 10	0.1	0.91	0.81	0.10	68,2 %
JAL-GT	4 × 4	0.1	1.28	0.72	0.56	60,6 %
JAL-GT	6 × 6	0.1	0.82	0.26	0.56	65,4 %
JAL-GT	10 × 10	0.25	0.15	-0,07	0.22	56,0 %

11.2.3. Análisis

La cobertura de estados varía entre 45,7 % y 68,2 %: moderada, no la cobertura casi total que haría la generalización trivial.

H7 confirmada en mapas grandes/poco densos: IQL 10 × 10, densidad 0.1 muestra el mejor gap (0,10) con la mayor cobertura (68,2 %).

H7 refutada en mapas pequeños y densos: el caso más dramático es IQL 4 × 4, densidad 0.25: la recompensa de test colapsa a 0,04 con un gap de 1,59. En mapas pequeños y densos,

cada semilla genera un layout radicalmente diferente. La cobertura media oculta que los estados *críticos* pueden ser distintos en cada mapa.

11.3 EXP10: Parejas heterogéneas de conceptos de solución (+0.5 puntos)

11.3.1. Motivación

Los experimentos anteriores usan parejas *homogéneas*: ambos agentes con el mismo concepto de solución. Esta ampliación estudia qué ocurre cuando los dos agentes JAL-GT usan conceptos distintos: un agente con Nash y el otro con Pareto.

Hipótesis (H8): la heterogeneidad de conceptos genera un conflicto de incentivos, por lo que esperamos rendimiento intermedio o inferior al de la mejor pareja homogénea.

11.3.2. Resultados




Figura 12: EXP10: parejas homogéneas (Nash+Nash, Pareto+Pareto) vs. heterogénea (Nash+Pareto) en 6×6 .

11.3.3. Análisis

Densidad 0.1: Nash+Pareto (9,84) rinde por debajo de Nash+Nash (11,63). Confirma H8: el conflicto de incentivos penaliza a la pareja heterogénea en baja densidad.

Densidad 0.25: Nash+Pareto (4,60) supera a *ambas* parejas homogéneas, Nash+Nash (4,31) y Pareto+Pareto (4,49). Este es el resultado más sorprendente del estudio y refuta H8 para alta densidad.

La explicación más plausible es una *división de roles emergente*: el agente Nash actúa como “cedente estable” y el agente Pareto optimiza el movimiento colectivo global. La complementariedad entre estabilidad local y eficiencia global resulta sinérgica cuando la densidad hace que los deadlocks sean costosos.

12 Análisis global y conclusiones

12.1 Verificación de las hipótesis

1. “JAL-GT $\geq$ IQL en recompensa colectiva.” **Refutada** en 5 de 6 configuraciones. IQL supera a JAL-GT en todos los tamaños excepto 10×10 con densidad 0.1. Causa: JAL-GT tiene un espacio de parámetros $10\times$ mayor y sufre underfitting severo ($\approx 0,6$ actualizaciones/entrada frente a $\approx 6,2$ de IQL).

2. **“IQL muestra mayor inestabilidad intra-run que JAL-GT.” Invertida:** JAL-GT es sistemáticamente *más* inestable (diferencia de hasta $12\times$). La causa es el bucle interno de JAL-GT (Q-update $\rightarrow$ recompute-policy $\rightarrow$ nuevo target). La firma de no-estacionariedad sobre IQL solo es visible en EXP5 10×10 (0,624 vs. 0,597).
3. **“La brecha crece con tamaño y densidad a favor de JAL-GT.” Invertida:** la brecha crece a favor de IQL. Los obstáculos no compensan la desventaja de datos de JAL-GT.
4. **“ γ alto es necesario para propagar la recompensa terminal.” Refutada:** el ganador es $\gamma = 0,9$ (el más bajo). En 4×4 con trayectorias cortas, $\gamma = 0,9^3 = 0,73$ es señal suficiente.
5. **“ ϵ alto reduce la varianza inter-seed.” Refutada:** el ganador es $\epsilon = 0,5$ (el más bajo), con la varianza más alta (2,01). En 4×4 , exploración moderada produce más explotación útil.
6. **“Ranking: Pareto/Welfare $>$ Nash $>$ Minimax.” Parcialmente confirmada.** Minimax es claramente el peor. Nash supera a Pareto en densidad baja; el ranking óptimo depende de la densidad y la calidad de los Q-values.
7. **“La brecha entre conceptos se amplifica con el tamaño.” Refutada técnicamente** por efecto suelo: Minimax ya falla completamente en 4×4 y no puede empeorar más en 10×10 .

12.2 Tabla resumen

Cuadro 7: Resumen de la comparativa algorítmica principal (recompensa en convergencia, media sobre 10 seeds).

Densidad	Algoritmo	4×4	6×6	10×10
0.1	IQL	13.19	11.99	9.14
0.1	JAL-GT	12.47	9.01	9.90
0.25	IQL	14.31	6.58	4.35
0.25	JAL-GT	13.86	4.49	1.97

En negrita el único caso donde JAL-GT supera a IQL (10×10 , densidad 0.1).

12.3 Conclusiones y recomendaciones

1. **Usar IQL como primera línea base antes de JAL-GT, especialmente con presupuesto de muestras limitado.** Con $\alpha = 0,01$ y 200 epochs, IQL supera a JAL-GT en la mayoría de configuraciones. JAL-GT solo muestra ventaja en mapas grandes (10×10) con densidad baja.
2. **Si se usa JAL-GT, elegir Pareto en densidad alta ($\geq 0,25$) y Nash en densidad baja.** Nash es más robusto a Q-values ruidosos; Pareto destaca cuando evitar deadlocks es crítico. Minimax nunca debe usarse en entornos cooperativos.
3. **Considerar parejas heterogéneas con roles complementarios.** Nash+Pareto supera a ambas parejas homogéneas en densidad 0.25, sugiriendo sinergia entre estabilidad local (Nash) y eficiencia global (Pareto).
4. **Calibrar γ según la longitud esperada de las trayectorias.** El par óptimo en 4×4 fue $\gamma = 0,9$; en mapas más grandes pueden ser necesarios valores más altos.

5. El *decay* lineal de ϵ es más robusto para JAL-GT. Para IQL, el exponencial puede ser útil cuando la velocidad de convergencia sea prioritaria, pero a costa de calidad final.
6. La representación local facilita el transfer, pero no lo garantiza en densidad alta. La cobertura del 52%–68 % permite buena generalización en mapas grandes/poco densos, pero en mapas pequeños y densos el gap train-test puede ser muy significativo (hasta 1,59).